**ESIC University**

Proyecto de Implantacion de Big Data I

# Documento de Implementacion

Tema 7 - Documentacion del Proyecto

Curso 2025 - 2026

# 1. Informacion del Documento

| | |
|---|---|
| **Proyecto** | API de Predicción de Productividad Estudiantil |
| **Equipo** | Laura Galán, Daniela Muñiz, Patricia Rivera, Mariela Rivero |
| **Fecha** | 10/05/2026 |
| **Version** | V1.0 |

# 2. Lenguaje del Proyecto

[Indicar el lenguaje de programacion principal utilizado en el proyecto.]

| | |
|---|---|
| **Lenguaje** | Python |
| **Version exacta** | 3.14.3 |
| **Entorno de ejecucion** | Script (.py) + API REST con Flask |

# 3. Version de Librerias

[Listar todas las librerias utilizadas con su version exacta. Se recomienda incluir el contenido del archivo requirements.txt.]

| Libreria | Version | Uso principal |
|---|---|---|
| fastapi | 0.135.1 | Framework web para construir la API REST con documentación Swagger automática |
| uvicorn | 0.42.0 | Servidor ASGI para ejecutar la aplicación FastAPI |
| pandas | 3.0.1 | Carga y manipulación del dataset |
| numpy | 2.4.2 | Operaciones numéricas y arrays |
| matplotlib | 3.10.8 | Generación de gráficos |
| scikit-learn | 1.8.0 | Entrenamiento del modelo Decision Tree y encoders |
| requests | 2.32.5 | Cliente HTTP utilizado en pruebas de la API |
| pydantic | 2.12.5 | Validación automática de los datos de entrada en los endpoints de la API |
| python-dotenv | 1.0.0 | Carga de variables de entorno desde el fichero .env (API Key de Groq) |

| | | |
|---|---|---|
| sqlite3 | (stdlib Python) | Persisitencia de datos en base de datos SQLite |
| Pickle | (stdlib Python) | Serialización y carga del modelo y encoders .pkl |

# 4. APIs Externas

El proyecto consume la siguiente API externa de inteligencia artificial para generar consejos personalizados al estudiante:

| Nombre | URL base | Uso en el proyecto | Autenticacion |
|---|---|---|---|
| Groq API | https://api.groq.com/openai/v1 | Generacion de consejos personalizados con IA (modelo LLaMA 3) segun nivel de productividad y habitos del estudiante | API Key via variable de entorno GROQ_API_KEY en fichero .env |

La API Key de Groq es gratuita y se obtiene en console.groq.com. No se incluye en el codigo ni en el repositorio: se gestiona mediante un fichero .env local que nunca se comparte ni se sube al contenedor Docker.

# 5. APIs Internas

La API REST está desarrollada con FastAPI y expone los siguientes endpoints en http://127.0.0.1:5000 (local) o http://localhost:5000 (Docker). La documentación interactiva Swagger está disponible en http://localhost:5000/docs:

| Metodo | Ruta | Descripcion | Body / Params | Respuesta |
|---|---|---|---|---|
| GET | / | Da información general de la API y listado de endpoints | Ninguno | JSON con nombre. Versión y endpoints |
| GET | /estadísticas | Da estaditicas generales del dataset (totales, medias, distribución) | Ninguno | JSON con métricas agragadas |
| GET | /estadisticas/genero | Da estadísticas agrupadas por género | Ninguno | JSON con medias por género |
| GET | /estadisticas/productividad | Da las estadísticas agrupadas por nivel de productividad | Ninguno | JSON comparativo ALTA/MEDIA/BAJA |

| | | | | |
|---|---|---|---|---|
| GET | /estudiantes | Da un listado paginado de estudiantes, con filtro opcional por nivel | pagina, limite, nivel (query) | JSON con lista y paginación |
| GET | /estudiante/<id> | Da los datos completos de un estudiante por su ID | id (path) | JSON con todos los campos del estudiante |
| POST | /predecir | Es la predicción del nivel de productividad con el modelo Decision Tree | JSON con 16 campos del estudiante | JSON con predicción y probabilidades |
| GET | /predicciones | Da el historial de las últimas 50 predicciones realizadas | Ninguno | JSON con lista y resumen estadístico |
| PUT | /estudiante/<id> | Da una actualización parcial de datos de un estudiante | id (path) + JSON con campos a modificar | JSON con mensaje de confirmación |
| DELETE | /estudiante/<id> | Permite eliminar un estudiante de la base de datos | id (path) | JSON con mensaje de confirmación |
| POST | /consejo | Genera 3 consejos personalizados con IA (Groq/LLaMA 3) segun el nivel de productividad y habitos del estudiante | JSON con nivel, horas estudio, sueno, distracción y estrés | JSON con consejos en texto, modelo IA y proveedor |

# 6. Base de Datos

| | |
|---|---|
| **Motor** | SQLite (stdlib Python, módulo sqlite3) |
| **Version** | Incluida con Python 3.14.3 |
| **Ruta del fichero** | data/estudiantes.db |
| **Tablas / Colecciones** | estudiantes, predicciones |

La tabla predicciones almacena cada llamada al endpoint /predecir con los campos: id, fecha, study_hours, sleep_hours, total_distraccion, nivel_predicho, probabilidad.

# 7. Lectura de Ficheros

| | |
|---|---|
| **Formato** | CSV |

| | |
|---|---|
| **Ruta del fichero** | PROYECTO FINAL BIG DATA/student_productivity_distraction_dataset_20000.csv |
| **Fuente** | Kaggle: https://www.kaggle.com/datasets/sehaj1104/student-productivity-and-digital-distraction-dataset |
| **Codificacion** | UTF-8 |
| **Separador (si CSV)** | , |
| **Columnas principales** | student_id (int), age (int), gender (str), study_hours_per_day (float), sleep_hours (float), phone_usage_hours (float), social_media_hours (float), youtube_hours (float), gaming_hours (float), breaks_per_day (int), coffee_intake_mg (float), exercise_minutes (float), assignments_completed (int), attendance_percentage (float), stress_level (int), focus_score (float), final_grade (float), productivity_score (float) |

# 8. Algoritmo de Machine Learning

| | |
|---|---|
| **Tipo de problema** | Clasificación multiclase (3 clases) |
| **Algoritmo** | Decision Tree Classifier |
| **Libreria y version** | scikit-learn 1.8.0 |
| **Hiperparametros** | max_depth=5 (evita overfitting), random_state=42 (reproducibilidad), stratify=y en train_test_split (mantiene proporción de clases) |
| **Features (variables X)** | age, gender_encoded, study_hours_per_day, sleep_hours, phone_usage_hours, social_media_hours, youtube_hours, gaming_hours, breaks_per_day, coffee_intake_mg, exercise_minutes, assignments_completed, attendance_percentage, stress_level, focus_score, final_grade, total_distraccion, ratio_estudio_distraccion |
| **Target (variable y)** | productividad_nivel (ALTA / MEDIA / BAJA) |
| **Metricas de evaluacion** | Accuracy global: ~81% \| F1-score por clase (ver classification_report en consola al ejecutar Proyecto_Principal.py) \| Matriz de confusión generada durante el entrenamiento |